Tổng hợp
các mô hình hàng đợi

Tham số, công thức, cách nhận diện và ví dụ có lời giải
cho M/M/1, M/M/1/K, M/M/c, M/M/c/c, M/M/c/K, M/M/∞, M/G/1
và mạng hàng đợi (Jackson, Burke, Kleinrock)

Câu hỏi mở đầu: *Mỗi mô hình có tham số và công thức khác nhau phải không?*
Đúng. Mỗi mô hình khác nhau ở **số server** c, **sức chứa** K, cách định nghĩa ρ và **công thức** p_0. Tuy vậy, tất cả đều đi theo **một khung 5 bước chung** (mục 1.3). Nắm khung này thì gặp mô hình nào cũng làm được.

Mục lục

1 Bức tranh tổng quan **2**

1.1 Các mô hình khác nhau ở đâu? . . . 2

1.2 Bảng ký hiệu dùng xuyên suốt . . . 2

1.3 Khung 5 bước dùng cho mọi mô hình . . . 3

1.4 Bản đồ quan hệ giữa các mô hình . . . 3

2 Kiến thức nền tảng **3**

2.1 Tiến trình Poisson và phân bố mũ . . . 3

2.2 Định lý Little . . . 4

2.3 Ký hiệu Kendall . . . 4

2.4 Quá trình sinh–tử: gốc của mọi công thức M/M . . . 5

3 Các mô hình một server **5**

3.1 M/M/1 (một server, hàng đợi vô hạn) . . . 5

3.2 M/M/1/K (một server, sức chứa hữu hạn) . . . 6

4 Các mô hình nhiều server **7**

4.1 M/M/c (nhiều server, hàng đợi vô hạn) và công thức Erlang C . . . 8

4.2 M/M/c/c (không có hàng đợi) và công thức Erlang B . . . 9

4.3 M/M/c/K (nhiều server, sức chứa hữu hạn): mô hình tổng quát . . . 10

4.4 M/M/∞ (vô số server) . . . 10

5 Mô hình mở rộng và quy tắc phục vụ **11**

5.1 M/G/1 và M/D/1 . . . 11

5.2 Quy tắc phục vụ và hàng đợi ưu tiên . . . 12

6 Mạng hàng đợi **12**

6.1 Phương trình lưu lượng . . . 13

6.2 Định lý Burke . . . 13

6.3 Mạng Jackson và định lý Jackson . . . 13

6.4 Xấp xỉ độc lập Kleinrock (KIA) . . . 14

7 Tổng kết và ôn thi **15**

7.1 Bảng so sánh tất cả các mô hình . . . 15

7.2 Nhận diện mô hình từ đề bài . . . 16

7.3 Mười lỗi hay mất điểm . . . 16

7.4 Mẹo tính nhanh khi đi thi . . . 16

1 Bức tranh tổng quan

1.1 Các mô hình khác nhau ở đâu?

Mọi mô hình trong môn học đều mô tả cùng một thứ: **khách hàng** (gói tin, cuộc gọi, tác vụ...) đi vào, **xếp hàng** nếu các server đều bận, được **phục vụ** rồi đi ra. Các mô hình chỉ khác nhau ở bốn điểm:

Điểm khác	Ý nghĩa	Ảnh hưởng tới công thức
Số server c	Bao nhiêu khách được phục vụ *cùng lúc*	Tốc độ đi của trạng thái i là $\min(i, c)\,\mu$ thay vì luôn bằng μ
Sức chứa K	Hệ thống chứa tối đa bao nhiêu khách	Có K hữu hạn thì có **xác suất từ chối** p_K và phải dùng λ_a
Định nghĩa ρ	$\rho = \lambda/\mu$ (1 server) hay $\rho = \lambda/(c\mu)$ (c server)	Đổi điều kiện ổn định và mọi công thức phía sau
Phân bố phục vụ	Mũ (M), hằng số (D), bất kỳ (G)	M/G/1 không dùng được chuỗi Markov, phải dùng công thức P-K

1.2 Bảng ký hiệu dùng xuyên suốt

Ký hiệu	Ý nghĩa	Đơn vị
λ	Tốc độ đến trung bình (của luồng Poisson)	khách/đơn vị t.gian
μ	Tốc độ phục vụ của **một** server; $1/\mu = T_S$ là thời gian phục vụ trung bình	khách/đơn vị t.gian
c	Số server (số quầy, số nhân, số kênh)	–
K	Sức chứa **toàn hệ thống** (gồm cả khách đang được phục vụ)	khách
$a = \lambda/\mu$	Cường độ tải (đơn vị *Erlang*); slide viết là $c\rho$	Erlang
ρ	Hệ số sử dụng của một server: $\rho = \lambda/\mu$ (1 server), $\rho = \lambda/(c\mu)$ (c server)	–
p_i	Xác suất trong hệ thống có đúng i khách (ở trạng thái dừng)	–
p_0	Xác suất hệ thống rỗng	–
N, N_Q	Số khách trung bình trong **hệ thống**, trong **hàng đợi**	khách
T, T_Q	Thời gian trung bình ở trong **hệ thống** (trễ), ở trong **hàng đợi** (chờ)	đơn vị t.gian
λ_a	Tốc độ đến *thực tế* (đã trừ khách bị từ chối): $\lambda_a = \lambda(1 - p_K)$	khách/đơn vị t.gian
P_Q	Xác suất khách đến phải chờ (công thức Erlang C)	–
P_B	Xác suất khách bị chặn/từ chối (công thức Erlang B)	–

Hệ thống và hàng đợi khác nhau

Hệ thống = hàng đợi + các server, nên luôn có $T = T_Q + \dfrac{1}{\mu}$ và $N = N_Q +$ (số server bận trung bình). Khi đề hỏi *"thời gian chờ"* thì thường là T_Q. Khi đề hỏi *"trễ"* hoặc *"từ lúc vào đến lúc xong"* thì là T.

1.3 Khung 5 bước dùng cho mọi mô hình

Quy trình giải một bài hàng đợi

B1. **Nhận diện mô hình** A/S/c/K (xem bảng ở mục 7.2). **Đổi đơn vị** về cùng một đơn vị thời gian.

B2. **Tính tham số**: λ, μ (nếu đề cho dung lượng kênh C và độ dài gói L thì $\mu = C/L$), $a = \lambda/\mu$, ρ. Kiểm tra **điều kiện ổn định** nếu $K = \infty$.

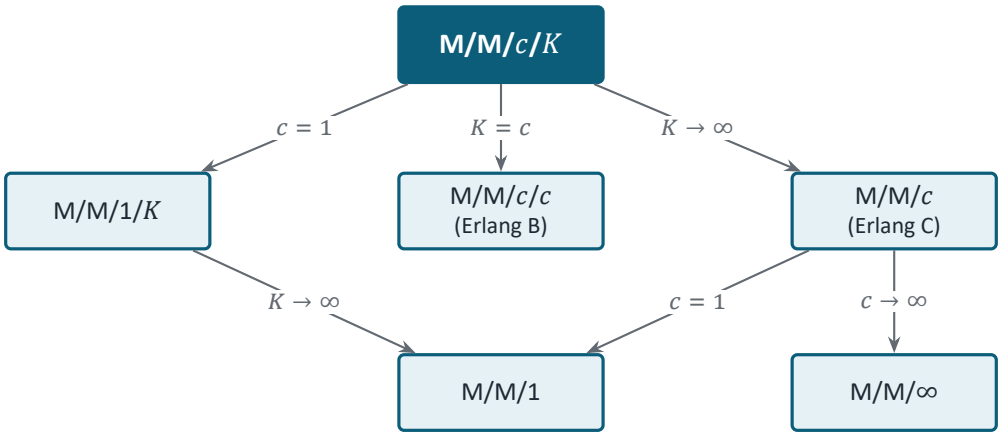
B3. **Vẽ chuỗi sinh–tử**, viết p_i theo p_0 (cân bằng luồng giữa hai trạng thái kề nhau).

B4. **Tính** p_0 từ điều kiện $\sum p_i = 1$. Từ đó suy ra các xác suất đề hỏi: p_K, P_Q, P_B...

B5. **Tính** N **hoặc** N_Q, sau đó dùng **định lý Little** để ra T, T_Q. Nếu có K hữu hạn thì dùng λ_a thay cho λ.

1.4 Bản đồ quan hệ giữa các mô hình

Mô hình tổng quát nhất trong môn là **M/M/c/K**. Các mô hình còn lại là trường hợp riêng của nó:



Nhờ quan hệ này, bạn có thể **tự kiểm tra** công thức. Ví dụ: đặt $c = 1$ vào công thức M/M/c phải ra đúng công thức M/M/1.

2 Kiến thức nền tảng

2.1 Tiến trình Poisson và phân bố mũ

Chữ **M** (Markov, *không nhớ*) trong ký hiệu Kendall đều dựa trên hai sự kiện sau.

Định lý 1: số lần đến trong khoảng t có phân bố Poisson

$$P\{N(t) = k\} = \frac{(\lambda t)^k}{k!} e^{-\lambda t}, \qquad k = 0, 1, 2, \ldots \qquad E[N(t)] = \lambda t$$

Định lý 2: khoảng thời gian giữa hai lần đến có phân bố mũ

$$P\{X \le t\} = 1 - e^{-\lambda t}, \qquad P\{X > t\} = e^{-\lambda t}, \qquad E[X] = \frac{1}{\lambda}$$

Các tính chất hay dùng:

- **Không nhớ:** $P\{X > s+t \mid X > s\} = P\{X > t\}$. Đã chờ bao lâu thì thời gian *còn lại* vẫn có cùng phân bố mũ như lúc đầu.
- **Ghép luồng:** gộp các luồng Poisson độc lập $\lambda_1, \lambda_2, \ldots$ được một luồng Poisson với tốc độ $\sum \lambda_i$.
- **Rẽ luồng:** mỗi khách được đưa sang nhánh j với xác suất p_j (độc lập nhau) thì nhánh j là luồng Poisson với tốc độ $p_j\lambda$.

Ví dụ: xe buýt

Xe buýt đến bến theo tiến trình Poisson, trung bình **5 phút/chuyến**. Một người vừa nhỡ một chuyến. Tính xác suất người đó đợi chuyến tiếp theo **ít hơn 3 phút**.

Lời giải. "5 phút/chuyến" là khoảng cách *trung bình* giữa hai chuyến, nên $\lambda = 1/5 = 0{,}2$ chuyến/phút. Nhờ tính không nhớ, "vừa nhỡ xe" nghĩa là bắt đầu chờ lại từ đầu:

$$P\{X < 3\} = 1 - e^{-0{,}2 \cdot 3} = 1 - e^{-0{,}6} \approx \boxed{0{,}451}$$

2.2 Định lý Little

Định lý Little: đúng cho mọi hệ thống ổn định

$$N = \lambda T \qquad N_Q = \lambda T_Q \qquad N_S = \lambda \cdot \frac{1}{\mu}$$

Nếu hệ thống **từ chối khách** (K hữu hạn) thì thay λ bằng $\lambda_a = \lambda(1 - p_K)$: $N = \lambda_a T, N_Q = \lambda_a T_Q$.

Định lý *không* phụ thuộc vào phân bố đến, phân bố phục vụ, số server hay quy tắc phục vụ. Biết 2 trong 3 đại lượng (số lượng, tốc độ, thời gian) là suy ra được đại lượng còn lại.

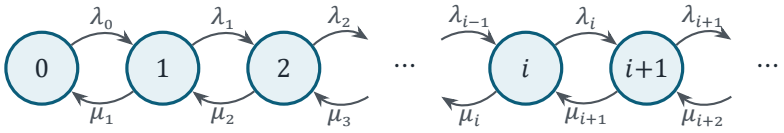
2.3 Ký hiệu Kendall

Slide viết đầy đủ là **A/S/m/[B]/[K]/[SD]**. Tài liệu này dùng dạng rút gọn **A/S/c/K**, trong đó K là *sức chứa hệ thống*.

Vị trí	Ý nghĩa	Giá trị thường gặp
A	Tiến trình đến	M (Poisson/mũ), D (tất định), E_r (Erlang bậc r), H_r (siêu mũ), G (tổng quát)
S	Tiến trình phục vụ	M, D, E_r, H_r, G (như trên)
c	Số server	$1, 2, \ldots, \infty$
K	Sức chứa hệ thống	Mặc định ∞. Có c server và B chỗ chờ thì $K = B + c$
–	Kích thước quần thể	Mặc định ∞ (nguồn khách vô hạn)
SD	Quy tắc phục vụ	Mặc định FCFS (FIFO). Ngoài ra có LCFS, SIRO, RR, PS...

2.4 Quá trình sinh–tử: gốc của mọi công thức M/M

Trạng thái của hệ thống là **số khách** i. Một khách đến (*sinh*) đưa trạng thái từ i lên $i+1$ với tốc độ λ_i. Một khách đi (*tử*) đưa trạng thái từ i về $i-1$ với tốc độ μ_i.



Phương trình cân bằng và nghiệm tổng quát

Ở trạng thái dừng, luồng đi qua giữa hai trạng thái kề nhau phải cân bằng:

$$\lambda_i\, p_i = \mu_{i+1}\, p_{i+1} \quad \Longrightarrow \quad p_i = p_0 \prod_{k=0}^{i-1} \frac{\lambda_k}{\mu_{k+1}}, \qquad p_0 = \Big[1 + \sum_{i\geq 1} \prod_{k=0}^{i-1} \frac{\lambda_k}{\mu_{k+1}}\Big]^{-1}$$

Mọi mô hình M/M/... chỉ khác nhau ở cách chọn λ_i, μ_i:

Mô hình	λ_i **(tốc độ đến ở trạng thái** i**)**	μ_i **(tốc độ đi ở trạng thái** i**)**
M/M/1	λ với mọi i	μ
M/M/1/K	λ nếu $i < K$, bằng 0 nếu $i = K$	μ
M/M/c	λ	$\min(i, c)\,\mu$
M/M/c/c	λ nếu $i < c$, bằng 0 nếu $i = c$	$i\,\mu$
M/M/c/K	λ nếu $i < K$, bằng 0 nếu $i = K$	$\min(i, c)\,\mu$
M/M/∞	λ	$i\,\mu$

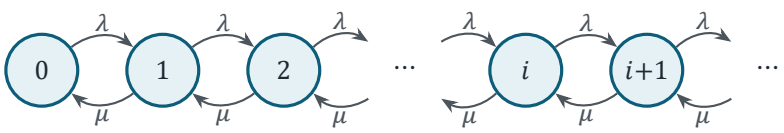
3 Các mô hình một server

3.1 M/M/1 (một server, hàng đợi vô hạn)

Nhận diện trong đề

Khách đến theo Poisson, thời gian phục vụ có phân bố mũ, **một** quầy/đường truyền/CPU, chỗ chờ "đủ lớn" hoặc "không giới hạn".
Ví dụ: một cổng ra của router có bộ đệm lớn, một quầy thu ngân.

Tham số: λ, μ. **Hệ số sử dụng:** $\rho = \lambda/\mu$. **Điều kiện ổn định:** $\rho < 1$ (tức $\lambda < \mu$).



Công thức M/M/1

Phân bố trạng thái	$p_i = (1-\rho)\,\rho^{\,i}, \qquad p_0 = 1-\rho, \qquad P\{\text{có} \geq k \text{ khách}\} = \rho^{\,k}$
Số khách trong hệ thống	$N = \dfrac{\rho}{1-\rho} = \dfrac{\lambda}{\mu-\lambda}$
Thời gian trong hệ thống	$T = \dfrac{N}{\lambda} = \dfrac{1}{\mu-\lambda} = \dfrac{1}{\mu}\cdot\dfrac{1}{1-\rho}$
Thời gian chờ trong hàng	$T_Q = T - \dfrac{1}{\mu} = \dfrac{\rho}{\mu-\lambda}$
Số khách trong hàng	$N_Q = \lambda T_Q = \dfrac{\rho^2}{1-\rho}$
Xác suất server bận	$1 - p_0 = \rho$

Phân bố của thời gian (với quy tắc FCFS)

Thời gian một khách ở trong **hệ thống** có phân bố mũ với tham số $\mu - \lambda$:

$$P\{T_{ht} \leq t\} = 1 - e^{-(\mu-\lambda)t} \qquad P\{T_{\text{chờ}} > t\} = \rho\, e^{-(\mu-\lambda)t}$$

Ví dụ: quầy tính tiền siêu thị mini

Khách đến quầy theo Poisson, trung bình **40 người/giờ**. Thời gian phục vụ có phân bố mũ, trung bình **1 phút**. Có một quầy, chỗ xếp hàng đủ cho mọi người. Tìm (a) thời gian chờ trung bình; (b) xác suất từ lúc vào hàng đến lúc trả tiền xong không quá 1,5 phút.

Lời giải. Đổi về phút: $\lambda = 40/60 = 2/3$ khách/phút, $\mu = 1$ khách/phút, nên $\rho = 2/3 < 1$ (ổn định).

(a) $T = \dfrac{1}{\mu-\lambda} = \dfrac{1}{1/3} = 3$ phút. Thời gian *chờ trong hàng* là $T_Q = T - 1/\mu =$ 2 phút. Nếu thầy hiểu "thời gian chờ" là T thì đáp án là 3 phút.

(b) $P\{T_{ht} \leq 1{,}5\} = 1 - e^{-(1/3)(1{,}5)} = 1 - e^{-0{,}5} \approx$ 0,393

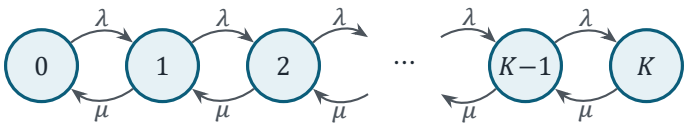
3.2 M/M/1/K (một server, sức chứa hữu hạn)

Nhận diện trong đề

Một server, bộ đệm **có giới hạn**: "tối đa K gói", "bộ đệm chứa B gói". Khách đến khi hệ thống đầy thì **bị từ chối/mất**.

Câu hỏi đặc trưng: *xác suất mất gói, xác suất bị từ chối, thông lượng thực tế*.

Tham số: λ, μ, K (sức chứa *tính cả* khách đang phục vụ, bộ đệm có $K-1$ chỗ). $\rho = \lambda/\mu$.
Không cần điều kiện ổn định, vì số trạng thái hữu hạn. $\rho \geq 1$ vẫn tính được.



Công thức M/M/1/K (với $\rho \neq 1$)

Phân bố trạng thái $\quad p_i = \rho^{\,i}\, p_0, \qquad p_0 = \dfrac{1-\rho}{1-\rho^{K+1}}, \qquad i = 0, \ldots, K$

Xác suất từ chối $\quad p_K = \dfrac{(1-\rho)\,\rho^K}{1-\rho^{K+1}}$

Tốc độ đến thực tế $\quad \lambda_a = \lambda\,(1-p_K) \qquad$ (kiểm tra: $\lambda_a = \mu(1-p_0)$)

Số khách trong hệ thống $\quad N = \dfrac{\rho}{1-\rho} - \dfrac{(K+1)\,\rho^{K+1}}{1-\rho^{K+1}}$

Số khách trong hàng $\quad N_Q = N - (1-p_0)$

Thời gian $\quad T = \dfrac{N}{\lambda_a} = \dfrac{1}{\lambda} \cdot \dfrac{1}{1-p_K} \cdot N, \qquad T_Q = \dfrac{N_Q}{\lambda_a}$

Trường hợp $\rho = 1$: $\quad p_i = \dfrac{1}{K+1}, \quad N = \dfrac{K}{2}.$

Bẫy thường gặp với M/M/1/K

- Dùng định lý Little thì phải dùng λ_a, không dùng λ. Khách bị từ chối không vào hệ thống.
- Đề cho "bộ đệm chứa B gói" và có 1 server thì $K = B + 1$.
- $N_Q \neq N - \rho$. Ở đây số server bận trung bình là $1 - p_0$, không phải ρ.

Ví dụ: router có bộ đệm nhỏ

Một cổng router nhận gói theo Poisson với $\lambda = 90$ gói/s. Thời gian truyền mỗi gói có phân bố mũ với $\mu = 100$ gói/s. Router chứa tối đa $K = 5$ gói (tính cả gói đang truyền). Tính xác suất mất gói, thông lượng, N, T, T_Q.

Lời giải. $\rho = 0{,}9$. $\quad p_0 = \dfrac{1-0{,}9}{1-0{,}9^6} = \dfrac{0{,}1}{0{,}4686} \approx 0{,}2134.$

$$p_5 = 0{,}9^5\, p_0 \approx \boxed{0{,}126} \text{ (mất 12,6\% số gói)}, \qquad \lambda_a = 90(1-0{,}126) \approx 78{,}66 \text{ gói/s}$$

$$N = \frac{0{,}9}{0{,}1} - \frac{6 \cdot 0{,}9^6}{1-0{,}9^6} \approx 2{,}195 \text{ gói}, \qquad T = \frac{N}{\lambda_a} \approx \boxed{27{,}9 \text{ ms}}$$

$$N_Q = N - (1-p_0) \approx 1{,}408 \text{ gói}, \qquad T_Q = \frac{N_Q}{\lambda_a} \approx \boxed{17{,}9 \text{ ms}}$$

Kiểm tra: $T - T_Q = 10$ ms $= 1/\mu$, khớp.

4 Các mô hình nhiều server

Với c server, ở trạng thái i có $\min(i, c)$ server đang bận, nên tốc độ đi là $\min(i, c)\,\mu$. Hai đại lượng cần phân biệt:

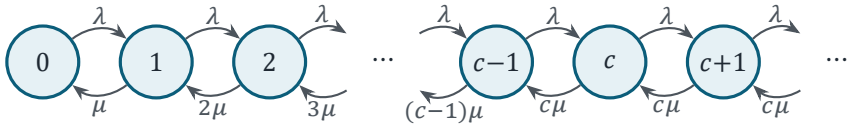
$$a = \frac{\lambda}{\mu} \text{ (cường độ tải, Erlang)} \qquad\qquad \rho = \frac{\lambda}{c\mu} = \frac{a}{c} \text{ (hệ số sử dụng } \textit{mỗi} \text{ server)}$$

4.1 M/M/c (nhiều server, hàng đợi vô hạn) và công thức Erlang C

Nhận diện trong đề

Có c **server song song** (CPU nhiều nhân, ngân hàng nhiều quầy, c đường truyền), chỗ chờ không giới hạn.
Câu hỏi đặc trưng: *xác suất phải đợi, thời gian chờ trung bình*.

Điều kiện ổn định: $\rho = \dfrac{\lambda}{c\mu} < 1$.



Công thức M/M/c

Phân bố trạng thái	$p_i = \dfrac{a^i}{i!}\,p_0 \ \ (i \le c), \qquad p_i = \dfrac{a^c}{c!}\,\rho^{\,i-c}\,p_0 = \dfrac{a^i}{c!\,c^{\,i-c}}\,p_0 \ \ (i \ge c)$
Xác suất rỗng	$p_0 = \left[\sum_{i=0}^{c-1} \dfrac{a^i}{i!} + \dfrac{a^c}{c!\,(1-\rho)}\right]^{-1}$
Erlang C (xác suất phải đợi)	$P_Q = \sum_{i \ge c} p_i = \dfrac{a^c}{c!\,(1-\rho)}\,p_0$
Số khách trong hàng	$N_Q = P_Q\,\dfrac{\rho}{1-\rho}$
Thời gian chờ	$T_Q = \dfrac{N_Q}{\lambda} = \dfrac{P_Q}{c\mu - \lambda}$
Thời gian trong hệ thống	$T = \dfrac{1}{\mu} + \dfrac{P_Q}{c\mu - \lambda}$
Số khách trong hệ thống	$N = \lambda T = c\rho + \dfrac{\rho\,P_Q}{1-\rho} = a + N_Q$

Số server bận trung bình $= a$. Phân bố thời gian chờ: $P\{T_{\text{chờ}} > t\} = P_Q\,e^{-(c\mu-\lambda)t}$.

Bẫy thường gặp với M/M/c

Hay nhầm ρ thành λ/μ. Với c server phải dùng $\rho = \lambda/(c\mu)$. Còn $\lambda/\mu = a$ có thể lớn hơn 1 mà hệ thống vẫn ổn định.
Tự kiểm tra: thay $c = 1$ thì $p_0 = 1-\rho$, $P_Q = \rho$, $T = 1/(\mu-\lambda)$, đúng bằng công thức M/M/1.

Ví dụ: CPU 4 nhân, bộ nhớ đủ lớn

Tác vụ đến theo Poisson, trung bình 20 task/μs. Thời gian xử lý có phân bố mũ, trung bình 0,08 μs. CPU có 4 nhân. Tính thời gian trung bình từ lúc nhận yêu cầu đến khi hoàn thành, và số tác vụ trung bình trong RAM.

Lời giải. $\lambda = 20$, $\mu = 1/0{,}08 = 12{,}5$ (task/μs), $c = 4$, nên $a = 1{,}6$ và $\rho = 0{,}4 < 1$.
Bảng $a^i/i!$: 1; 1,6; 1,28; 0,6827; 0,2731 (với $i = 0..4$). Tổng 4 số đầu là 4,5627.

$$p_0 = \left[4{,}5627 + \frac{0{,}2731}{0{,}6}\right]^{-1} = \frac{1}{5{,}0178} \approx 0{,}1993, \qquad P_Q = \frac{0{,}2731}{0{,}6} \cdot 0{,}1993 \approx 0{,}0907$$

$$N_Q = 0{,}0907 \cdot \frac{0{,}4}{0{,}6} \approx 0{,}0605, \qquad T_Q = \frac{0{,}0605}{20} \approx 0{,}0030\ \mu s, \qquad T = 0{,}08 + 0{,}0030 \approx \boxed{0{,}083\ \mu s}$$

$$N = \lambda T = 1{,}6 + 0{,}0605 \approx \boxed{1{,}66 \text{ tác vụ}}$$

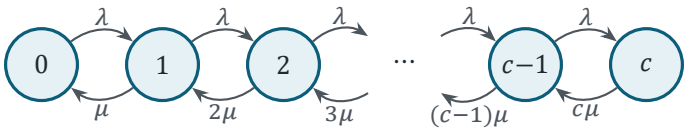
Đề không cho dung lượng một tác vụ nên "lượng bộ nhớ" tính bằng số tác vụ.

4.2 M/M/c/c (không có hàng đợi) và công thức Erlang B

Nhận diện trong đề

c kênh/server và **không có chỗ chờ**. Khách đến lúc tất cả kênh đều bận thì bị **mất ngay**.
Ví dụ kinh điển: tổng đài điện thoại có c trung kế. Câu hỏi đặc trưng: *xác suất tắc nghẽn, cần bao nhiêu kênh*.

Không cần điều kiện ổn định. Không có hàng đợi nên $N_Q = 0, T_Q = 0$.



Công thức M/M/c/c

Phân bố trạng thái $\quad p_i = \dfrac{a^i}{i!}\,p_0, \qquad p_0 = \left[\sum_{i=0}^{c} \dfrac{a^i}{i!}\right]^{-1}, \qquad i = 0, \dots, c$

Erlang B (xác suất tắc nghẽn) $\quad P_B = p_c = \dfrac{a^c/c!}{\sum_{i=0}^{c} a^i/i!}$

Tính bằng đệ quy (dễ bấm máy) $\quad B(0) = 1, \qquad B(k) = \dfrac{a\,B(k-1)}{k + a\,B(k-1)}, \qquad P_B = B(c)$

Lưu lượng được phục vụ $\quad \lambda_a = \lambda(1 - P_B), \qquad N = a\,(1 - P_B)$ (số kênh bận trung bình)

Thời gian trong hệ thống $\quad T = 1/\mu$

Ví dụ: tổng đài nội bộ

Cuộc gọi đến theo Poisson, trung bình 2 cuộc/phút. Thời gian đàm thoại trung bình 2 phút (phân bố mũ). Tổng đài có 5 kênh. (a) Tính xác suất một cuộc gọi bị chặn. (b) Cần ít nhất bao nhiêu kênh để xác suất chặn dưới 1%?

Lời giải. $a = \lambda/\mu = 2 \cdot 2 = 4$ Erlang.

(a) $P_B = \dfrac{4^5/5!}{1 + 4 + 8 + 10{,}667 + 10{,}667 + 8{,}533} = \dfrac{8{,}533}{42{,}867} \approx \boxed{0{,}199}$. Khoảng 20% cuộc gọi bị chặn.

(b) Tính tiếp bằng đệ quy $B(k)$:

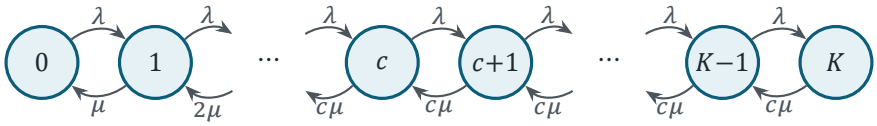
c	5	6	7	8	9	10	11
P_B	0,199	0,117	0,063	0,030	0,013	**0,0053**	0,0019

Vậy cần $\boxed{c = 10}$ kênh.

4.3 M/M/c/K (nhiều server, sức chứa hữu hạn): mô hình tổng quát

Nhận diện trong đề

c server, hệ thống chứa tối đa K khách ($c \le K$). Câu hỏi có **cả** "xác suất bị từ chối" **và** "xác suất phải đợi".



Công thức M/M/c/K

Phân bố trạng thái $\quad p_i = \dfrac{a^i}{i!}\,p_0 \;\; (0 \le i \le c), \qquad p_i = \dfrac{a^c}{c!}\,\rho^{\,i-c}\,p_0 \;\; (c \le i \le K)$

Xác suất rỗng $\quad p_0 = \Big[\sum_{i=0}^{c-1} \dfrac{a^i}{i!} + \dfrac{a^c}{c!}\sum_{j=0}^{K-c}\rho^{\,j}\Big]^{-1}, \qquad \sum_{j=0}^{K-c}\rho^{\,j} = \dfrac{1-\rho^{K-c+1}}{1-\rho}$

Xác suất từ chối $\quad p_K = \dfrac{a^c}{c!}\,\rho^{\,K-c}\,p_0$

Xác suất phải đợi $\quad P_{\text{đợi}} = \sum_{i=c}^{K-1} p_i = \dfrac{a^c}{c!}\cdot\dfrac{1-\rho^{K-c}}{1-\rho}\cdot p_0$

Số khách trong hàng $\quad N_Q = \sum_{i=c}^{K}(i-c)\,p_i$

Các đại lượng còn lại $\quad \lambda_a = \lambda(1-p_K), \quad N = N_Q + \dfrac{\lambda_a}{\mu}, \quad T = \dfrac{N}{\lambda_a}, \quad T_Q = \dfrac{N_Q}{\lambda_a}$

Khi $\rho = 1$ thì thay $\sum_{j=0}^{K-c}\rho^{\,j}$ bằng $K-c+1$. **Không cần điều kiện ổn định.**

Ví dụ: CPU 4 nhân, cache tối đa 10 tác vụ

Cùng số liệu với ví dụ M/M/4 ở trên nhưng hệ thống chỉ chứa tối đa $K = 10$ tác vụ. Tính xác suất một tác vụ bị từ chối và xác suất phải đợi.

Lời giải. $a = 1{,}6$, $\rho = 0{,}4$, $c = 4$, $K = 10$, nên $K - c = 6$.

$$p_0 = \Big[4{,}5627 + 0{,}2731\cdot\frac{1-0{,}4^7}{0{,}6}\Big]^{-1} = \frac{1}{5{,}0170} \approx 0{,}1993$$

$$p_{10} = 0{,}2731\cdot 0{,}4^6\cdot 0{,}1993 \approx \boxed{2{,}23\times 10^{-4}} \qquad P_{\text{đợi}} = 0{,}2731\cdot\frac{1-0{,}4^6}{0{,}6}\cdot 0{,}1993 \approx \boxed{0{,}0903}$$

Nếu "10 tác vụ" chỉ là phần chờ trong cache thì $K = 10 + 4 = 14$. Hãy đọc kỹ đề.

4.4 M/M/∞ (vô số server)

Mỗi khách đến đều được phục vụ ngay, không ai phải chờ. $\quad \mu_i = i\mu$.

Công thức M/M/∞

$$p_i = \frac{a^i}{i!}\, e^{-a} \text{ (phân bố Poisson)}, \qquad N = a = \frac{\lambda}{\mu}, \qquad T = \frac{1}{\mu}, \qquad N_Q = T_Q = 0$$

Ứng dụng: mô hình hóa số người dùng đang online, số phiên đang mở, khi tài nguyên coi như không giới hạn.

5 Mô hình mở rộng và quy tắc phục vụ

Phạm vi

Mục 5.1 (M/G/1, M/D/1) **không có trong slide** của môn. Phần này để tham khảo và để hiểu vì sao giả thiết "phục vụ mũ" lại quan trọng. Mục 5.2 tóm tắt phần lý thuyết về quy tắc phục vụ có trong slide.

5.1 M/G/1 và M/D/1

Khi thời gian phục vụ X **không** có phân bố mũ thì không còn chuỗi sinh–tử. Lúc đó dùng công thức **Pollaczek–Khinchine (P-K)**:

Công thức P-K cho M/G/1 ($\rho = \lambda E[X] < 1$)

$$T_Q = \frac{\lambda\, E[X^2]}{2(1-\rho)}, \qquad E[X^2] = \mathrm{Var}(X) + \big(E[X]\big)^2, \qquad T = T_Q + E[X], \qquad N_Q = \lambda T_Q$$

Mô hình	$E[X^2]$	T_Q
M/M/1 (mũ)	$2/\mu^2$	$\dfrac{\rho}{\mu(1-\rho)}$
M/D/1 (hằng số, ví dụ gói cùng độ dài)	$1/\mu^2$	$\dfrac{\rho}{2\mu(1-\rho)}$

Nhận xét: với cùng ρ, thời gian chờ của **M/D/1 chỉ bằng một nửa M/M/1**. Thời gian phục vụ càng biến động thì hàng đợi càng dài. Ví dụ với $\rho = 0{,}8$ và $\mu = 1$: M/M/1 có $T_Q = 4$, M/D/1 có $T_Q = 2$.

5.2 Quy tắc phục vụ và hàng đợi ưu tiên

Quy tắc	Mô tả
FCFS / FIFO	Đến trước phục vụ trước. Đây là mặc định khi đề không nói gì
LCFS / LIFO	Đến sau phục vụ trước (kiểu ngăn xếp)
SIRO (RANDOM)	Chọn ngẫu nhiên, mọi khách đang chờ có xác suất được chọn như nhau
SJF / SPF	Ưu tiên công việc có thời gian xử lý ngắn nhất
RR (Round Robin)	Mỗi khách được phục vụ một lát thời gian cố định, chưa xong thì quay lại cuối hàng
PS (Processor Sharing)	Mọi khách chia đều năng lực phục vụ
FB (Foreground–Background)	Cố gắng đạt hiệu quả như SJF mà không cần biết trước thời gian phục vụ

Thuật toán xếp hàng trong router:

- **FIFO Queuing**: đơn giản, không cần cấu hình, nhưng không phân biệt ưu tiên. Một nguồn phát quá nhiều có thể làm tăng trễ của mọi luồng khác.
- **PQ (Priority Queuing)**: nhiều hàng có mức ưu tiên khác nhau, hàng ưu tiên cao luôn được phục vụ trước. Không tự thích nghi khi điều kiện mạng thay đổi.
- **CQ (Custom Queuing)**: mỗi loại lưu lượng có một phần hàng đợi riêng, phục vụ xoay vòng (round-robin) để chia băng thông theo tỷ lệ. Không tự thích nghi.
- **WFQ (Weighted Fair Queuing)**: giống CQ nhưng trọng số được hệ thống tự điều chỉnh (qua báo hiệu QoS), tự thích ứng với lưu lượng.

Hàng đợi có ưu tiên, chia theo cách xử lý khi khách ưu tiên cao đến:

- **Không ưu tiên phục vụ trước** (non-preemptive, HOL): khách ưu tiên cao vẫn phải đợi khách đang được phục vụ xong.
- **Ưu tiên phục vụ trước** (preemptive): ngắt ngay khách ưu tiên thấp. Có ba kiểu: *phục hồi* (resume, làm tiếp từ chỗ dừng), *không lấy mẫu lại* (làm lại từ đầu với thời gian cũ), *lấy mẫu lại* (làm lại với thời gian phục vụ mới).

6 Mạng hàng đợi

Mạng gồm nhiều nút hàng đợi nối với nhau. Sau khi được phục vụ ở một nút, khách chuyển sang nút khác hoặc rời mạng theo các xác suất định tuyến.

Ký hiệu	Ý nghĩa
λ	Tổng tốc độ đến trung bình từ bên ngoài vào mạng
μ_i	Tốc độ phục vụ của nút i
r_{sj}	Xác suất khách từ nguồn được đưa vào nút j
r_{jk}	Xác suất khách rời nút j đi tiếp tới nút k
r_{jd}	Xác suất khách rời nút j đi ra đích (rời mạng)
θ_i	**Thông lượng** trung bình qua nút i (tốc độ đến tổng tại nút i)

6.1 Phương trình lưu lượng

Cân bằng luồng tại mỗi nút

$$\theta_j = \lambda\, r_{sj} + \sum_k \theta_k\, r_{kj} \qquad \text{với mọi nút } j$$

Luồng vào nút j = luồng đến từ ngoài + tổng các luồng chuyển tới từ những nút khác (kể cả từ chính nó).
Điều kiện ổn định của mạng: $\rho_i = \theta_i/\mu_i < 1$, tức $\mu_i > \theta_i$, với **mọi** nút i.

6.2 Định lý Burke

Đầu ra của một hàng M/M/1 (hoặc M/M/c) **ổn định** có tốc độ λ cũng là một **luồng Poisson với tốc độ** λ. Hơn nữa, trạng thái của hàng đợi tại thời điểm t độc lập với quá trình rời đi trước t.
Hệ quả: với mạng nối tiếp (không có vòng phản hồi), đầu vào của mọi nút đều là Poisson. Nhờ vậy có thể phân tích từng nút như một M/M/1 riêng.

6.3 Mạng Jackson và định lý Jackson

Mạng Jackson (mạng mở) có các đặc điểm: mỗi nút là hàng FIFO, hàng đợi vô hạn, thời gian phục vụ có phân bố mũ Exp(μ_i), khách từ ngoài đến theo Poisson, định tuyến theo xác suất cố định.

Định lý Jackson: coi mỗi nút là một M/M/1 độc lập

$$p(n_1, n_2, \ldots, n_M) = \prod_{i=1}^{M} (1-\rho_i)\,\rho_i^{n_i}, \qquad \rho_i = \frac{\theta_i}{\mu_i}$$

$$E(N_i) = \frac{\rho_i}{1-\rho_i}, \qquad E(T_i) = \frac{1}{\theta_i}\cdot\frac{\rho_i}{1-\rho_i} = \frac{1}{\mu_i - \theta_i}$$

$$N_{\text{mạng}} = \sum_i E(N_i), \qquad T_{\text{mạng}} = \frac{N_{\text{mạng}}}{\lambda} = \sum_i \frac{\theta_i}{\lambda} E(T_i), \qquad P\{\text{mạng rỗng}\} = \prod_i (1-\rho_i)$$

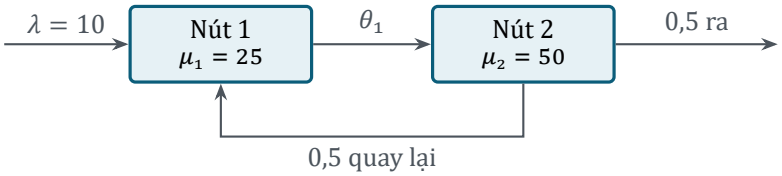
θ_i/λ là **số lần trung bình một khách đi qua nút** i. Nút có vòng phản hồi thì giá trị này lớn hơn 1.

Bẫy khi tính trễ toàn mạng

Trễ toàn mạng là $N_{\text{mạng}}$ chia cho λ (tốc độ đến từ *bên ngoài*), **không** chia cho $\sum \theta_i$. Có vòng phản hồi thì một khách đi qua một nút nhiều lần, nên $\sum \theta_i > \lambda$.

Ví dụ: mạng hai nút có phản hồi

Gói đến nút 1 theo Poisson với $\lambda = 10$ gói/s. Xong nút 1 thì sang nút 2. Xong nút 2 thì gói quay lại nút 1 với xác suất 0,5, hoặc rời mạng với xác suất 0,5. Cho $\mu_1 = 25$, $\mu_2 = 50$ gói/s.



Lời giải. Phương trình lưu lượng: $\theta_1 = 10 + 0{,}5\,\theta_2$, $\theta_2 = \theta_1$. Suy ra $\theta_1 = \theta_2 = 20$ gói/s.
$\rho_1 = 20/25 = 0{,}8$, $\rho_2 = 20/50 = 0{,}4$. Cả hai đều nhỏ hơn 1 nên mạng ổn định.

$$E(N_1) = \frac{0{,}8}{0{,}2} = 4, \qquad E(N_2) = \frac{0{,}4}{0{,}6} \approx 0{,}667, \qquad N_{\text{mạng}} \approx 4{,}667 \text{ gói}$$

$$T_{\text{mạng}} = \frac{4{,}667}{10} \approx \boxed{0{,}467 \text{ s}}, \qquad P\{\text{mạng rỗng}\} = 0{,}2 \cdot 0{,}6 = \boxed{0{,}12}$$

Kiểm tra: mỗi gói qua mỗi nút trung bình $20/10 = 2$ lần, nên $T = 2\cdot\frac{1}{25-20} + 2\cdot\frac{1}{50-20} = 0{,}4 + 0{,}067 = 0{,}467$ s. Khớp.

6.4 Xấp xỉ độc lập Kleinrock (KIA)

Dùng để tính trễ trong **mạng truyền dữ liệu nhiều luồng**. Mỗi liên kết (i,j) được coi là một hàng M/M/1 độc lập, dù trên thực tế độ dài gói giữ nguyên khi đi qua các liên kết.

x_s	Tốc độ gói của luồng s (đi theo một đường cố định từ nguồn tới đích)
λ_{ij}	Tốc độ đến trên liên kết (i,j) = tổng x_s của các luồng đi qua liên kết đó. Nếu luồng s chỉ đưa một phần $f_{ij}(s)$ qua liên kết thì $\lambda_{ij} = \sum_s f_{ij}(s)\,x_s$
μ_{ij}	Tốc độ phục vụ của liên kết: $\mu_{ij} = C_{ij}/L$ (dung lượng chia cho độ dài gói trung bình)
γ	Tổng tốc độ đến của toàn mạng: $\gamma = \sum_s x_s$
d_{ij}	Trễ lan truyền trên liên kết (i,j)

Công thức KIA

$$N_{ij} = \frac{\lambda_{ij}}{\mu_{ij} - \lambda_{ij}}, \qquad N = \sum_{(i,j)} \frac{\lambda_{ij}}{\mu_{ij} - \lambda_{ij}}, \qquad T = \frac{1}{\gamma}\sum_{(i,j)} \frac{\lambda_{ij}}{\mu_{ij} - \lambda_{ij}} = \sum_{(i,j)} \alpha_{ij} T_{ij}$$

với $\alpha_{ij} = \lambda_{ij}/\gamma$ và $T_{ij} = \dfrac{1}{\mu_{ij} - \lambda_{ij}}$. Nếu tính thêm **trễ lan truyền**:

$$T = \frac{1}{\gamma}\sum_{(i,j)} \left(\frac{\lambda_{ij}}{\mu_{ij} - \lambda_{ij}} + \lambda_{ij}\, d_{ij} \right)$$

Trễ của một luồng đi theo đường p: $T_p = \displaystyle\sum_{(i,j)\in p} \left(\frac{\rho_{ij}}{\mu_{ij} - \lambda_{ij}} + \frac{1}{\mu_{ij}} + d_{ij} \right)$, với $\rho_{ij} = \lambda_{ij}/\mu_{ij}$.

Ví dụ: ba nút A–B–C

Liên kết A→B có $\mu = 500$ gói/s, liên kết B→C có $\mu = 400$ gói/s. Có ba luồng: s_1: A→C với 100 gói/s; s_2: A→B với 150 gói/s; s_3: B→C với 200 gói/s. Bỏ qua trễ lan truyền.

Lời giải. $\lambda_{AB} = 100 + 150 = 250$, $\lambda_{BC} = 100 + 200 = 300$, $\gamma = 450$ gói/s.

$$N_{AB} = \frac{250}{500 - 250} = 1, \qquad N_{BC} = \frac{300}{400 - 300} = 3, \qquad T = \frac{1 + 3}{450} \approx \boxed{8{,}89 \text{ ms}}$$

Trễ riêng của luồng s_1 (đi qua cả hai liên kết): $T_{s_1} = \dfrac{1}{250} + \dfrac{1}{100} = 4 + 10 = \boxed{14 \text{ ms}}$.

7 Tổng kết và ôn thi

7.1 Bảng so sánh tất cả các mô hình

Mô hình	ρ / điều kiện	p_0	Kết quả đặc trưng
M/M/1	$\rho = \frac{\lambda}{\mu} < 1$	$1 - \rho$	$N = \frac{\rho}{1-\rho}, T = \frac{1}{\mu - \lambda}, T_Q = \frac{\rho}{\mu - \lambda}, N_Q = \frac{\rho^2}{1-\rho}$
M/M/1/K	$\rho = \frac{\lambda}{\mu}$, không cần < 1	$\frac{1-\rho}{1-\rho^{K+1}}$	$p_K = \rho^K p_0$; $N = \frac{\rho}{1-\rho} - \frac{(K+1)\rho^{K+1}}{1-\rho^{K+1}}; T = \frac{N}{\lambda_a}$
M/M/c	$\rho = \frac{\lambda}{c\mu} < 1$	$\left[\sum_{i=0}^{c-1} \frac{a^i}{i!} + \frac{a^c}{c!(1-\rho)}\right]^{-1}$	$P_Q = \frac{a^c p_0}{c!(1-\rho)}; T_Q = \frac{P_Q}{c\mu - \lambda}$; $N = a + N_Q$
M/M/c/c	$a = \frac{\lambda}{\mu}$, không cần điều kiện	$\left[\sum_{i=0}^{c} \frac{a^i}{i!}\right]^{-1}$	$P_B = \frac{a^c}{c!} p_0$ (Erlang B); $T = \frac{1}{\mu}$; $N = a(1 - P_B)$
M/M/c/K	$\rho = \frac{\lambda}{c\mu}$, không cần < 1	$\left[\sum_{i=0}^{c-1} \frac{a^i}{i!} + \frac{a^c}{c!}\sum_{j=0}^{K-c} \rho^j\right]^{-1}$	$p_K = \frac{a^c}{c!}\rho^{K-c} p_0$; $P_{\text{đợi}} = \sum_{i=c}^{K-1} p_i$; dùng λ_a
M/M/∞	không cần điều kiện	e^{-a}	$p_i = \frac{a^i}{i!} e^{-a}; N = a; T = \frac{1}{\mu}$
M/G/1	$\rho = \lambda E[X] < 1$	$1 - \rho$	$T_Q = \frac{\lambda E[X^2]}{2(1-\rho)}$ (P-K)
Jackson	$\frac{\theta_i}{\mu_i} < 1 \; \forall i$	$\prod_i (1 - \rho_i)$	$N = \sum \frac{\rho_i}{1-\rho_i}; T = \frac{N}{\lambda}$
KIA	$\lambda_{ij} < \mu_{ij}$	–	$T = \frac{1}{\gamma} \sum \frac{\lambda_{ij}}{\mu_{ij} - \lambda_{ij}}$

7.2 Nhận diện mô hình từ đề bài

Dấu hiệu trong đề	Kết luận
"đến theo tiến trình Poisson", "khoảng cách giữa hai lần đến có phân bố mũ"	A = M
"thời gian phục vụ/xử lý có phân bố mũ", "độ dài gói có phân bố mũ"	S = M
"thời gian phục vụ cố định", "gói có độ dài cố định"	S = D
"một quầy", "một đường truyền", "một CPU"	$c = 1$
"4 nhân", "3 quầy", "c kênh"	$c = 4,\ 3,\ \ldots$
"đủ chỗ cho tất cả", "bộ nhớ đủ lớn", "không giới hạn"	$K = \infty$
"tối đa K khách trong hệ thống"	K
"bộ đệm (chỗ chờ) chứa B"	$K = B + c$
"không có chỗ chờ", "bận thì cuộc gọi bị mất"	$K = c$ (Erlang B)
Hỏi "xác suất phải đợi" với nhiều server	Erlang C (M/M/c)
Hỏi "xác suất từ chối/mất gói/tắc nghẽn"	K hữu hạn, tính p_K
Nhiều router/nút nối nhau, có xác suất định tuyến	Mạng Jackson
Nhiều luồng đi qua các liên kết có dung lượng C_{ij}	KIA

7.3 Mười lỗi hay mất điểm

Kiểm tra trước khi nộp bài

1. **Không đổi đơn vị**: λ theo giờ nhưng thời gian phục vụ theo phút; Byte và bit (1 Byte = 8 bit); ms và s.
2. Đề cho dung lượng C (bps) và độ dài gói L (bit) mà quên tính $\mu = C/L$.
3. "Trung bình 5 phút/chuyến" là $1/\lambda$, không phải λ.
4. Với c server dùng nhầm $\rho = \lambda/\mu$. Đúng phải là $\rho = \lambda/(c\mu)$.
5. Hệ thống có K hữu hạn mà vẫn dùng λ trong định lý Little. Phải dùng $\lambda_a = \lambda(1 - p_K)$.
6. Nhầm T (trong hệ thống) với T_Q (trong hàng đợi).
7. Coi "bộ đệm B" là K, trong khi $K = B + c$.
8. Nhầm **Erlang B** (không có hàng đợi, xác suất bị chặn) với **Erlang C** (có hàng đợi, xác suất phải chờ).
9. Mạng có phản hồi: tính trễ toàn mạng phải chia cho λ **từ bên ngoài**, không chia cho $\sum \theta_i$.
10. Quên **kiểm tra điều kiện ổn định** trước khi dùng công thức của hệ thống vô hạn.

7.4 Mẹo tính nhanh khi đi thi

- Lập sẵn **bảng** $a^i/i!$ cho $i = 0, \ldots, c$. Mọi công thức M/M/c, M/M/c/c, M/M/c/K đều dùng lại bảng này.
- Erlang B: dùng đệ quy $B(k) = \dfrac{aB(k-1)}{k + aB(k-1)}$ thay vì tính giai thừa lớn.

- Tổng cấp số nhân: $\sum_{j=0}^{n} \rho^j = \frac{1-\rho^{n+1}}{1-\rho}$.
- **Tự kiểm tra** bằng ba hệ thức: $T - T_Q = 1/\mu$; $N - N_Q$ = số server bận trung bình ($= a$ khi không từ chối, $= \lambda_a/\mu$ khi có từ chối); $\sum p_i = 1$.